MUNICIPALIDAD DE LA CISTERNA

Informe Ejecutivo y Proyección Presupuestaria a 2 Años · Chatbot Municipal Cisternin

> **Destinatario:** Jefatura de Informática y Dirección Municipal

> **Preparado por:** Mathias Arriagada — Ingeniero a cargo del Proyecto Chatbot Cisternin

> **Fecha de emisión:** Octubre 2026

> **Período evaluado:** 2 Años (24 Meses operativos)

1. Resumen Ejecutivo del Proyecto

El chatbot municipal **Cisternin** es un asistente virtual 24/7 diseñado para orientar a los vecinos en trámites de licencias de conducir, permisos de circulación, farmacia comunal, subsidios y dependencias municipales. Cuenta con base vectorial local (RAG) de 582 fragmentos oficiales y derivación directa al WhatsApp municipal cuando se requiere atención humana.

2. Arquitectura de Despliegue y Soberanía Tecnológica

- **Aislamiento del portal web:** Se integra mediante un widget flotante en React que no toca la base de datos de la web ni su CMS (Strapi).
- **Túnel Público (Cloudflare Tunnel):** Otorga acceso seguro HTTPS bajo el dominio municipal **sin abrir puertos en el firewall** y con protección anti-DDoS sin costo de licencia (/usr/bin/bash CLP).
- **Túnel Privado (Tailscale Mesh VPN):** Permite al equipo de IA realizar actualizaciones y soporte remoto en caliente (Zero-Downtime) mediante conexión cifrada de grado militar sin costo (/usr/bin/bash CLP).

3. Modelo Matemático y Cálculo de Costos de la API de IA (Google Gemini)

El cálculo de costos de la API se modela en base a una estimación de **300 vecinos atendidos por día**, con 3 preguntas promedio por vecino durante 30 días al mes:

Parámetros de Entrada:

• Usuarios diarios (N) = 300 vecinos/día

• Consultas por usuario (Q) = 3 preguntas/usuario

• Consultas mensuales (C_mes) = 300 × 3 × 30 = 27.000 consultas/mes

• Tokens promedio de entrada (T_in) = 1.200 tokens (Instrucción + Contexto RAG + Pregunta)

• Tokens promedio de salida (T_out) = 200 tokens (Respuesta concisa)

• Tarifa Google Gemini Flash Input (P_in) = /usr/bin/bash,075 USD / 1.000.000 tokens

• Tarifa Google Gemini Flash Output (P_out) = /usr/bin/bash,300 USD / 1.000.000 tokens

• Tipo de cambio referencial (TC) = 50 CLP / USD

Fórmulas de Costo:

Tokens_in_mensual = 27.000 × 1.200 = 32.400.000 tokens (32,4 M)

```
Tokens_out_mensual = 27.000 × 200 = 5.400.000 tokens (5,4 M)
```

```
Costo_mes (USD) = (32,4 × /usr/bin/bash,075) + (5,4 × /usr/bin/bash,300) =
```

```
,43 + ,62 = ,05 USD/mes
```

```
Costo_mes (CLP) = ,05 USD × 50 CLP = .847,5 ≈ .850 CLP/mes
```

4. Proyección Presupuestaria a 2 Años (24 Meses)

Concepto de Infraestructura	Costo Mensual	Costo Anual (12m)	Total 2 Años (24m)	Estado / Observación
API Google Gemini Flash (27.000 consultas/mes)	.850 CLP	6.170 CLP	**2.340 CLP** (~7,20 USD)	Inferencia de IA y comprensión de lenguaje
Cloudflare Tunnel (Túnel público HTTPS)	/usr/bin/ bash CLP	/usr/bin/ bash CLP	**/usr/bin/ bash CLP**	**Costo /usr/bin/bash** (Plan Zero Trust incluido)
Tailscale VPN (Túnel privado de gestión)	/usr/bin/ bash CLP	/usr/bin/ bash CLP	**/usr/bin/ bash CLP**	**Costo /usr/bin/bash** (Plan Community hasta 100 nodos)
Base de Datos RAG ChromaDB	/usr/bin/ bash CLP	/usr/bin/ bash CLP	**/usr/bin/ bash CLP**	**Costo /usr/bin/bash** (Soberanía local en servidor)
TOTAL BASE PROYECTADO (2 Años)	.850 CLP	6.170 CLP	**2.340 CLP**	Consumo proyectado de 648.000 consultas

5. Conclusión y Recomendación de Adquisición

> **Recomendación Presupuestaria:**
>
> El costo matemático estricto para operar Cisternin durante **2 años completos** atendiendo a 300 personas diarias es de apenas **2.340 CLP**.

> Considerando contingencias, campañas de alta demanda (como el Permiso de Circulación en marzo) y crecimiento vecinal, se sugiere solicitar una asignación presupuestaria de **00.000 a 00.000 CLP**.
>
> Con dicho monto, la Municipalidad de La Cisterna asegura el funcionamiento pleno, autónomo y con alta velocidad del chatbot durante más de 24 meses, con alertas de límite de gasto configurables en Google Cloud para evitar cualquier desvío presupuestario.