ILUSTRE MUNICIPALIDAD DE LA CISTERNA
DIRECCIÓN DE INFORMÁTICA Y TECNOLOGÍA
PROYECTO ASISTENTE VIRTUAL CIUDADANO (CISTERNIN)

TÉRMINOS DE REQUERIMIENTO TÉCNICO Y FINANCIERO

ADQUISICIÓN DE SERVICIO DE API DE INTELIGENCIA ARTIFICIAL GENERATIVA (LLM) PARA ATENCIÓN VECINAL 24/7

DESTINATARIO:	Administración Municipal / Dirección de Finanzas / Jefatura de Informática
UNIDAD TÉCNICA:	Equipo de Desarrollo e Innovación Tecnológica (Proyecto Cisternin)
FECHA:	Octubre de 2026
OBJETO ÚNICO:	Contratación de consumo de API de Modelo de Lenguaje (LLM) empresarial

1. ANTECEDENTES Y ESTADO OPERATIVO DEL SISTEMA

La Municipalidad de La Cisterna dispone de la solución integral de Asistente Virtual Ciudadano ("Cisternin"), desarrollada y lista para su despliegue en producción. Toda la arquitectura técnica, plataformas de administración y base de conocimiento comunal ya se encuentran completamente construidas e integradas, sin requerir inversión en desarrollo de software ni compras de equipamiento físico adicional.

- **Componentes ya operativos al 100% ($0 CLP requeridos):**
  - Motor conversacional RAG (FastAPI / Python) con búsqueda semántica local.
  - Base de datos vectorial municipal (ChromaDB) con 583 fragmentos oficiales indexados (trámites, licencias, farmacia, veterinaria, Tarjeta Vecino, aseo y autoridades).
  - Portal público de atención ciudadana y widget web flotante para inserción en www.cisterna.cl.
  - Panel de administración (/admin), portal de documentación con reportes en Excel (/docs) y canal de derivación oficial a WhatsApp Municipal.
  - Túnel seguro de alta disponibilidad perimetral (sin abrir puertos en el firewall municipal).

2. DEFINICIÓN DEL REQUERIMIENTO: SERVICIO DE INTELIGENCIA ARTIFICIAL

El único componente que se solicita adquirir es el **Servicio de API de Modelo de Lenguaje (LLM de grado empresarial)**, necesario para que el bot genere las respuestas conversacionales a los vecinos de forma ininterrumpida y con tiempo de respuesta inferior a 1,5 segundos.

- **Especificaciones técnicas requeridas (Neutralidad Tecnológica - Ley 19.886):**
  1. Protocolo de integración: API estándar RESTful HTTPS (JSON entrada/salida).
  2. Capacidad y latencia: Modelo optimizado de alta velocidad (Time to First Token < 1,5s).

3. Ventana de contexto: Mínimo 128.000 tokens para análisis integral de decretos y ordenanzas.
4. Privacidad y Seguridad (Ley N° 19.628): El proveedor no debe retener ni utilizar las consultas de los vecinos para entrenamiento de modelos públicos.
5. Modelo de cobro: Pago por uso exacto (Pay-As-You-Go) con control de gasto máximo mensual (Budget Cap).

3. MODELO DE COSTOS Y PRESUPUESTO SOLICITADO

El costo real de cada interacción vecinal es sumamente bajo debido a la eficiencia del motor RAG municipal, que inyecta únicamente los fragmentos necesarios. El costo directo estimado es de apenas **$0,14 CLP por consulta ciudadana.**

Concepto Financiero	Monto Mensual (CLP)	Monto Anual (CLP)	Proyección 2 Años (24m)
Consumo Base Estimado (1.000 consultas/día)	$4.275 CLP (~$4,50 USD)	$51.300 CLP	$102.600 CLP
Presupuesto Solicitado (Techo Operativo)	**$100.000 CLP**	**$1.200.000 CLP (1,2 M)**	**$2.400.000 CLP (2,4 M)**
Capacidad de Atención Cubierta	Hasta 701.750 consultas/mes	Hasta 8,4 Millones/año	Hasta 16,8 Millones
Costo por Consulta Vecinal	$0,14 CLP / consulta	$0,14 CLP / consulta	$0,14 CLP / consulta

4. JUSTIFICACIÓN DE LA ASIGNACIÓN DE $100.000 CLP/MES ($1,2 MILLONES/AÑO)

Si el consumo base promedio para 1.000 atenciones diarias representa ~$4.275 CLP mensuales, se justifica solicitar un presupuesto de **$100.000 CLP mensuales ($1.200.000 CLP anuales)** por los siguientes motivos operativos y de gestión pública:

1. Variabilidad por vecino: Un vecino no siempre realiza una sola pregunta; comúnmente formula consultas sucesivas (3 a 8 preguntas) para resolver dudas de subsidios, requisitos vehiculares o licencias de conducir.
2. Picos estacionales de alta demanda: Durante períodos de alta afluencia (marzo por Permisos de Circulación, mayo por patentes comerciales), el tráfico municipal se multiplica hasta por cinco. El presupuesto asegura capacidad para más de 700.000 consultas mensuales sin interrupción.
3. Garantía de Cero Caídas (Zero-Downtime): Un crédito de $100.000 CLP/mes garantiza que el servicio nunca se suspenda por 'cuota excedida' o límites de saldo.
4. Eficiencia y protección del erario municipal: Bajo el modelo Pay-As-You-Go, el municipio solo paga por las consultas efectivamente realizadas. Si en un mes se consumen $12.000 CLP, los

$88.000 CLP restantes no se pierden ni se cobran, quedando resguardados por el límite mensual configurado.

5. PROCEDIMIENTO DIRECTO PARA LA PUESTA EN MARCHA

Paso 1: Aprobación del requerimiento presupuestario de $100.000 CLP/mes ($1.200.000 CLP/año) para servicio de API de IA.
Paso 2: Habilitación de la cuenta de nube municipal con límite de gasto (Budget Cap) configurado en $100.000 CLP/mes.
Paso 3: Entrega de la credencial API al equipo técnico para su vinculación con el bot (proceso de 5 minutos).
Paso 4: Inserción del widget en www.cisterna.cl y habilitación del servicio ciudadano 24/7.

_____

MATHIAS ARRIAGADA
Desarrollo e Innovación — Proyecto Cisternin
Ilustre Municipalidad de La Cisterna