MUNICIPALIDAD DE LA CISTERNA

Informe Ejecutivo, Infraestructura de Red y Presupuesto Operativo · Chatbot Cisternin

> **Para:** Jefatura de Informática y Dirección de Administración y Finanzas (DAF)

> **De:** Mathias Arriagada — Ingeniero de Software a cargo del Proyecto Chatbot Municipal

> **Fecha de emisión:** 16 de Octubre de 2026

> **Marco temporal:** Evaluación Anual (12 Meses) y Plurianual a 2 Años (24 Meses)

1. Resumen Ejecutivo

El chatbot municipal **Cisternin** es un asistente virtual 24/7 diseñado para orientar a la comunidad en trámites de licencias de conducir, permisos de circulación, farmacia comunal, tarjeta vecino, aseo y subsidios. Opera con una base vectorial local (RAG) de 583 fragmentos oficiales y derivación directa al WhatsApp de atención al vecino. Se solicita una **asignación presupuestaria anual de $1.200.000 CLP ($100.000 CLP mensuales)**, proyectando **$2.400.000 CLP a 2 años**, para cubrir de forma holgada e ininterrumpida el consumo de la API de Inteligencia Artificial (Google Gemini 1.5 Flash).

2. Alojamiento en Subdominio e Infraestructura de Red

2.1. Alojamiento en Subdominio Municipal

Cisternin se desplegará en el servidor municipal y se publicará de cara a la comunidad bajo un subdominio institucional propio (por ejemplo, **chatbot.lacisterna.cl** o **cisternin.lacisterna.cl**). En el archivo de configuración del sistema (`.env`), el equipo de TI municipal simplemente debe definir el dominio oficial en la siguiente línea:

```
# Archivo .env — Configuración de Dominio Oficial
DOMAIN_NAME=chatbot.lacisterna.cl # <-- Reemplazar aquí con el subdominio municipal definitivo
```

En el servidor DNS municipal, solo se requiere agregar un registro CNAME que apunte dicho subdominio al túnel seguro de la aplicación.

2.2. Implementación de Red y Seguridad Perimetral

La conectividad hacia Internet se implementa mediante un esquema de **doble túnel** que garantiza máxima seguridad:

- **Túnel Público (Cloudflare Tunnel / cloudflared):** Conecta el contenedor de Cisternin (puerto interno 8000) con el subdominio municipal público mediante conexiones salientes cifradas por TLS. **No requiere abrir puertos de entrada (ni puerto 80 ni 443) en el firewall perimetral de la municipalidad**, eliminando la superficie de

ataque y blindando la red municipal con protección anti-DDoS sin costo de licencia ($0 CLP).
- **Túnel Privado de Mantenimiento (Tailscale Mesh VPN):** Canal privado cifrado con protocolo WireGuard que permite al equipo de desarrollo realizar actualizaciones de documentos, monitoreo y recargas suaves en caliente (Zero-Downtime) sin exponer interfaces administrativas a Internet ($0 CLP).

2.3. Perfiles de Acceso y Gestión del Administrador Público

El sistema cuenta con una separación estricta de responsabilidades y accesos:

- **Acceso Vecinal / Ciudadano (`/chat`):** Interfaz pública sin autenticación donde los vecinos interactúan con Cisternin. Puede consumirse directamente como página web o incrustarse como widget flotante en el portal municipal.
- **Acceso del Administrador Público (`/admin` y `/docs`):** Panel de control exclusivo para el **Administrador Público** municipal (funcionario encargado de atención al vecino o jefatura de área), protegido por contraseña (`ADMIN_PANEL_CLAVE`). Desde este panel, el Administrador Público puede:
  - Supervisar en tiempo real los documentos cargados en la base de conocimiento y los chunks indexados.
  - Monitorear el ranking de preguntas frecuentes de los vecinos para detectar necesidades comunales.
  - Activar o suspender en un clic el interruptor de derivación a ejecutivos de WhatsApp.
  - Descargar reportes oficiales consolidados en CSV/Excel para la alcaldía y concejo municipal.

3. Modelamiento Matemático en LaTeX del Costo de IA (Google Gemini 1.5 Flash)

A continuación se detalla la modelación matemática rigurosa en notación LaTeX para el cálculo de consumo de tokens:

> **Definición de Variables y Parámetros:**

> $U_d = 300$: Vecinos o usuarios únicos atendidos por día.

> $D_m = 30$: Días operativos considerados al mes.

> $Q_p \in [1, 10]$: Preguntas por persona/sesión (variable estocástica según complejidad).

> $T_{in} = 1.200$: Tokens promedio de entrada (Prompt institucional + RAG + consulta).

> $T_{out} = 200$: Tokens promedio de salida (respuesta concisa estructurada).

> $P_{in} = 0,075 imes 10^{-6} ext{ USD/token}$: Tarifa oficial Google Gemini Flash Input.

> $P_{out} = 0,300 imes 10^{-6} ext{ USD/token}$: Tarifa oficial Google Gemini Flash Output.

> $TC = 950 ext{ CLP/USD}$: Tipo de cambio oficial referencial.

1. Ecuación del Costo Unitario por Consulta (c_q):

$$c_q = \left(T_{in} \cdot P_{in} + T_{out} \cdot P_{out} ight) \cdot TC$$ $$c_q =

\left(1.200 \cdot 0,075 imes 10^{-6} + 200 \cdot 0,300 imes 10^{-6} ight) imes 950$$ $$c_q =

(0,000090 + 0,000060) imes 950 = 0,000150 ext{ USD} imes 950 = 0,1425 ext{ CLP/consulta}$$

2. Función de Gasto Mensual (G_{mes}):

$$G_{mes}(Q_p) = U_d \cdot D_m \cdot Q_p \cdot c_q = 300 \cdot 30 \cdot Q_p \cdot 0,1425 =

1.282,5 \cdot Q_p ext{ CLP/mes}$$

3. Evaluación del Escenario Base Teórico ($ar{Q}_p = 3$ preguntas/vecino):

$$C_{mes}^{base} = 300 \cdot 30 \cdot 3 = 27.000 ext{ consultas/mes}$$ $$G_{mes}^{base} =

27.000 \cdot 0,1425 = \$3.847,5 pprox \$3.850 ext{ CLP/mes} \quad (4,05 ext{ USD/mes})$$ $

$G_{anual}^{base} = \$3.847,5 imes 12 pprox \$46.170 ext{ CLP/año}$$ $$G_{2 ext{ años}}^{base}

= \$3.847,5 imes 24 pprox \$92.340 ext{ CLP (en 24 meses)}$$

4. Justificación Técnica del Presupuesto Solicitado ($1.200.000 CLP/Año)

En la realidad comunal, la variable Q_p (preguntas por persona) es impredecible: muchos vecinos realizan múltiples consultas sucesivas sobre requisitos sociales, o acuden con casos familiares complejos. Además, existen **picos estacionales masivos** (como marzo con el Permiso de Circulación o vencimientos de patentes en julio) donde la afluencia diaria U_d puede quintuplicarse. Para asegurar que el servicio jamás se detenga, se solicita la asignación presupuestaria de:

Presupuesto Fijo Asignado (Techo de Seguridad Operativa):

$$B_{mes} = \$100.000 ext{ CLP/mes} \quad (pprox 105,26 ext{ USD/mes})$$ $$B_{anual} = B_{mes}

imes 12 = \$1.200.000 ext{ CLP/año} \quad (1,2 ext{ Millones CLP})$$ $$B_{2 ext{ años}} =

B_{anual} imes 2 = \$2.400.000 ext{ CLP a 2 años} \quad (2,4 ext{ Millones CLP})$$

Capacidad Máxima de Consultas Soportada (C_{max}):

$$C_{max}^{mes} =

```
rac{B_{mes}}{c_q} =
```

```
rac{100.000}{0,1425} pprox 701.754 ext{ consultas al mes}$$ $$C_{max}^{anual} = 701.754 imes 12
```

```
pprox 8.421.048 ext{ consultas al año}$$
```

5. Cuadro Comparativo de Costos de Infraestructura y Presupuesto

Componente del Sistema	Costo Mensual	Costo Anual (12m)	Total 2 Años (24m)	Observación Técnica
Costo Base Teórico Gemini Flash	$3.850 CLP	$46.170 CLP	$92.340 CLP	Para 27.000 consultas/mes (3 preguntas/persona)
Cloudflare Tunnel (Subdominio público)	$0 CLP	$0 CLP	$0 CLP	**Licencia $0** (Plan Zero Trust oficial)
Tailscale VPN (Túnel privado seguro)	$0 CLP	$0 CLP	$0 CLP	**Licencia $0** (Red privada WireGuard)
ChromaDB Vector Store (Base local)	$0 CLP	$0 CLP	$0 CLP	**Licencia $0** (Soberanía en servidor municipal)
PRESUPUESTO ASIGNADO SOLICITADO	**$100.000 CLP**	**$1.200.000 CLP**	**$2.400.000 CLP**	**Techo de contingencia (hasta 701.754 consultas/mes)**

6. Garantías Financieras y Control de Gasto Público

Gobernanza y Transparencia Financiera:

- **Facturación por Consumo Real (*Pay-as-you-go*):** Google Cloud factura únicamente por los tokens efectivamente consultados. Si en un mes el consumo es de $8.000 CLP, la municipalidad solo paga $8.000 CLP; el remanente de los $100.000 CLP permanece intacto en arcas municipales.
- **Alertas de Límite de Gasto (Budget Caps):** Se configuran en Google Cloud alertas automáticas al 50%, 80% y 100% de los $100.000 CLP mensuales, impidiendo sobrecostos accidentales.
- **Disponibilidad Total:** Brinda la tranquilidad a la municipalidad de que ante crisis o emergencias comunales, Cisternin responderá con máxima capacidad sin interrupciones.